

Análise de sobrevivência e confiabilidade

Introdução



Prof. Paulo Cerqueira Jr
Faculdade de Estatística - FAEST
Instituto de Ciências Exatas e Naturais - ICEN

<https://github.com/paulocerqueirajr> 

Representação do tempo de sobrevivência

Representação do tempo de sobrevivência

- Uma representação simples do mecanismo de censura aleatória é feita usando duas variáveis aleatórias.
- Seja Y uma variável aleatória representando o tempo de falha de um paciente;
- Seja C uma variável aleatória independente de T (censura não informativa), representando o tempo de censura associado a este paciente.
- O tempo observado é representado por

$$t = \min(Y, C) \quad e \quad \delta = \begin{cases} 1, & Y \leq C \\ 0, & Y > C \end{cases}$$

Representação dos dados de sobrevivência

Exemplos

Tabela: Dados de 32 pacientes com AIDS.

	3	18	29	54	60	84	110	112	116	123
145	151	151	158	173	194	214	329	331	371	408
490	514	541	555	688	780	801	858	887	998	

Tabela: Tempos de sobrevivência observados no estudo de hepatite

Grupo	Tempo de sobrevivência em semanas
Controle	1+, 2+, 3, 3, 3+, 5+, 5+, 16+, 16+, 16+, 16+, 16+, 16+
Esteróide	1, 1, 1, 1+, 4+, 5, 7, 8, 10, 10+, 12+, 16+, 16+, 16+

Especificando o Tempo de Sobrevivência

Função de sobrevivência

Qual é a probabilidade de um paciente com aids sobreviver 365 dias ou mais? Isto é, qual a probabilidade de T ser maior do que um determinado valor $t = 365$? Ou, mais formalmente, qual é $P(T > 365)$?

- Esta é uma das principais funções probabilísticas usadas para descrever estudos de sobrevivência.
- A função de sobrevivência é definida como a probabilidade de uma observação não falhar até um certo tempo t , ou seja, a probabilidade de uma observação sobreviver ao tempo t .
- Em termos probabilísticos, isto é escrito como

$$S(t) = P(T > t).$$

- Em consequência, a função de distribuição acumulada é dada por $F(t) = 1 - S(t)$.
- Definida como a probabilidade de uma observação não sobreviver ao tempo t .


Especificando o Tempo de Sobrevivência

Função de sobrevivência

Estas curvas, supostas representarem as funções de sobrevivência de dois grupos diferentes de pacientes, o grupo 1 tratado com a droga A e o grupo 2 com a droga B.

Note, por exemplo, que o tempo de vida dos pacientes do grupo 1 é superior ao dos pacientes do grupo 2.

Para os pacientes do grupo 1, o tempo para o qual cerca de 50% (tempo mediano) deles estarão mortos é de 20 anos, enquanto que para os pacientes do grupo 2, este tempo é menor (10 anos).



Representação dos dados de sobrevivência

- Os dados de sobrevivência para o indivíduo i ($i = 1, \dots, n$) sob estudo, são representados, em geral, pelo par (t_i, δ_i) ,
- t_i : o tempo de evento ou de censura e δ_i a variável indicadora de falha ou censura, ou seja,

$$\delta_i = \begin{cases} 1, & t_i \text{ é um tempo de evento} \\ 0, & t_i \text{ é um tempo de censura} \end{cases}$$

- Na presença de covariáveis medidas no i -ésimo indivíduo tais como, dentre outras, $x_i = (\text{sexo}, \text{idade}, \text{tratamento recebido})$,

$$(y_i, \delta_i, x_i).$$

- Na presença de censura intervalar temos $(l_i, u_i, \delta_i, x_i)$, em que l_i e u_i são os limites inferiores e superiores observados, respectivamente.

Especificando o Tempo de Sobrevivência

Função Risco ou taxa de falha

- Qual é o risco de um paciente com aids vir a óbito após sobreviver 365 dias?
- Esse risco de morrer aumenta ou diminui com o tempo?

$h(t)$: probabilidade instantânea de um indivíduo sofrer o evento em um intervalo de tempo t e $(t + \epsilon)$ dado que ele sobreviveu até o tempo t .

Sendo ϵ infinitamente pequeno, $\lambda(t)$ expressa o risco instantâneo de ocorrência de um evento, dado que até então o evento não tenha ocorrido.

Especificando o Tempo de Sobrevivência

Função Risco ou taxa de falha

$$h(t) = \lim_{\epsilon \rightarrow 0} \frac{P(t < T < t + \epsilon | T \geq t)}{\epsilon}$$

- $h(t)$ também é denominada:
 - função ou taxa de incidência,
 - força de infecção,
 - taxa de falha,
 - força de mortalidade,
 - força de mortalidade condicional.
- Apesar do nome risco, $h(t)$ é uma taxa (tempo⁻¹).

Pode assumir qualquer valor positivo (não é probabilidade)

Especificando o Tempo de Sobrevivência

Estimando a função taxa de falha

Na ausência de censuras, temos que a fórmula para estimar a função de taxa de falha é dada por

$$\hat{h}_x(t) = \frac{N_x(t)}{R_x(t) \times \Delta_x}$$

$N_x(t)$: Número de eventos observados no intervalo de classe x .

Δ_x : amplitude de x .

Uma maneira alternativa de estimar $\lambda(t)$ é utilizar as relações entre $S(t)$, $f(t)$ e $h(t)$.

Comum nas tábuas de vida - demografia.

Especificando o Tempo de Sobrevivência

Estimando função de sobrevivência

Intervalo	$R_x(t)$	$\hat{S}_x(t)$
(0,3]	32	1.00000
(3,18]	31	0.96875
(18,29]	30	0.93750
(29,54]	29	0.90625
(54,60]	28	0.87500
(60,84]	27	0.84375
(84,110]	26	0.81250
(110,112]	25	0.78125
(112,116]	24	0.75000
(116,123]	23	0.71875
(123,134]	22	0.68750
(134,145]	21	0.65625

Intervalo	$R_x(t)$	$\hat{S}_x(t)$
(145,151]	20	0.62500
(151,158]	18	0.56250
(158,173]	17	0.53125

Tabela: Estimativa da sobrevivência para os 32 pacientes com AIDS.

Especificando o Tempo de Sobrevivência

Estimando a função taxa de falha


Intervalo	$R_x(t)$	$N_x(t)$	Δ_x	$\hat{h}_x(t)$
(0,3]	32	1	3	0.01042
(3,18]	31	1	15	0.00215
(18,29]	30	1	11	0.00303
(29,54]	29	1	25	0.00138
(54,60]	28	1	6	0.00595
(60,84]	27	1	24	0.00154
(84,110]	26	1	26	0.00148
(110,112]	25	1	2	0.02000
(112,116]	24	1	4	0.01042
(116,123]	23	1	7	0.00621
(123,134]	22	1	11	0.00413
(134,145]	21	1	11	0.00433

Intervalo	$R_x(t)$	$N_x(t)$	Δ_x	$\hat{h}_x(t)$
(145,151]	20	2	6	0.01667
(151,158]	18	1	7	0.00794
(158,173]	17	1	15	0.00392

Tabela: Estimativa da função de taxa de falha para os 32 pacientes com AIDS.


Especificando o Tempo de Sobrevivência

Comportamentos da função de taxa de falha



Especificando o Tempo de Sobrevivência

Comportamentos da função de taxa de falha



Especificando o Tempo de Sobrevivência

Função taxa de falha acumulada

- Qual o risco de um paciente com aids vir a óbito no primeiro ano após o diagnóstico?
- Qual é o risco dele vir a óbito nos primeiros 2 anos?

$H(t)$: função de taxa de falha (risco) acumulada.

Mede o risco de ocorrência do evento até o tempo t .

É a soma (integral) de todos os riscos em todos os tempos até o tempo t

$$H(t) = \int_0^t h(u) du.$$

Também é uma taxa, logo não está restrita ao intervalo $[0; 1]$.

Especificando o Tempo de Sobrevivência

Estimando $H(t)$

$$\hat{H}_x(t) = \sum_{i=1}^{x-1} \hat{h}_x(t) \times \Delta_x.$$

- O risco acumulado até o tempo t é igual a:
 - o risco acumulado até o tempo $t - 1$ mais
 - o risco instantâneo do período anterior vezes o intervalo de tempo até t .

Especificando o Tempo de Sobrevivência

Estimando $H(t)$

Intervalo	$R_x(t)$	$N_x(t)$	Δ_x	$\hat{h}_x(t)$	$\hat{H}_x(t)$
(0,3]	32	1	3	0.01042	0.00000
(3,18]	31	1	15	0.00215	0.03125
(18,29]	30	1	11	0.00303	0.06351
(29,54]	29	1	25	0.00138	0.09684
(54,60]	28	1	6	0.00595	0.13132
(60,84]	27	1	24	0.00154	0.16704
(84,110]	26	1	26	0.00148	0.20408
(110,112]	25	1	2	0.02000	0.24254
(112,116]	24	1	4	0.01042	0.28254
(116,123]	23	1	7	0.00621	0.32420
(123,134]	22	1	11	0.00413	0.36768
(134,145]	21	1	11	0.00433	0.41314

Intervalo	$R_x(t)$	$N_x(t)$	Δ_x	$\hat{h}_x(t)$	$\hat{H}_x(t)$
(145,151]	20	2	6	0.01667	0.46076
(151,158]	18	1	7	0.00794	0.56076
(158,173]	17	1	15	0.00392	0.61631

Tabela: Estimativa da função de taxa acumulada para os 32 pacientes com AIDS.

Especificando o Tempo de Sobrevivência

Tempo médio e médio residual

Outras duas quantidades de interesse em análise de sobrevivência são: o tempo médio de vida e a vida média residual.

A primeira é obtida pela área sob a função de sobrevivência. Isto é,

$$t_m = \int_0^{\infty} S(t) dt.$$

Já a vida média residual é definida condicional a um certo tempo de vida t . Ou seja, para indivíduos com idade t esta quantidade mede o tempo médio restante de vida. Isto é,

$$vmr(t) = \frac{\int_t^{\infty} S(u) du}{S(t)}.$$

Especificando o Tempo de Sobrevivência

- A variável aleatória não-negativa T , que representa o tempo de evento, é usualmente especificada em análise de sobrevivência pela:
 - sua função de sobrevivência.
 - ou pela função de taxa de falha (risco).
- Estas duas funções, e funções relacionadas, que são extensivamente usadas na análise de dados de sobrevivência são apresentadas a seguir.

Especificando o Tempo de Sobrevivência

Relações entre funções

$$S(t) = 1 - F(t)$$

$$h(t) = -\frac{d \ln S(t)}{dt}$$

$$h(t) = \frac{f(t)}{S(t)}$$

$$h(t) = \frac{f(t)}{1 - F(t)}$$

$$H(t) = -\ln(S(t))$$

$$S(t) = \exp(-H(t))$$

Especificando o Tempo de Sobrevivência

No R

- O pacote mais usual de análise de sobrevivência no R é o `survival`.
- Ele contém uma grande quantidade de métodos para o assunto.

A função `Surv` serve para definir um objeto do tipo de sobrevivência, para duas notações:

`Surv(tempo, status)` `Surv(inicio, final, status)`

Vamos ver um exemplo no R.

Especificando o Tempo de Sobrevivência

No R

- O pacote mais usual de análise de sobrevivência no R é o *survival*.
- Ele contém uma grande quantidade de métodos para o assunto.

A função `Surv` serve para definir um objeto do tipo de sobrevivência, para duas notações:

- **`Surv(tempo, status)`**
- **`Surv(inicio, final, status)`**

Vamos ver um exemplo no R.

Estimação não-paramétrica

Introdução

- Introdução
- Kaplan-Meier
- Nelson-Aalen
- Intervalos de confiança
- Tempo Mediano de sobrevivência
- Kaplan-Meier com estratificação
- Teste de Log-Rank
- Teste de Peto

Introdução

Duas formas não paramétricas de estimação das funções de sobrevivência:

- Kaplan-Meier – $S(t)$
- Nelson-Aalen – $H(t)$

Ambas técnicas envolvem censura.

Sem suposições sobre a distribuição do tempo.

Estimação não-paramétrica

Estimador de Kaplan-Meier

- O estimador não-paramétrico de Kaplan-Meier, proposto por Kaplan e Meier (1958), para estimar a função de sobrevivência.
- A probabilidade de sobreviver até o tempo t é estimada considerando que a sobrevivência até cada tempo é independente da sobrevivência até outros tempos.
- A probabilidade de chegar até o tempo t é o produto da probabilidade de chegar até cada um dos tempos anteriores.
- Estimador produto (ou estimador limite produto)

Estimação não-paramétrica

Estimador de Kaplan-Meier

- Sejam $t_1 < t_2 < \dots < t_m$ os m tempos onde ocorreram os eventos;
- $R(t_j)$ é o total de pessoas a risco no tempo t_j .
- $\Delta N(t_j)$ é o número de eventos ocorridos precisamente em t_j .
- Para os m tempos t_j em que ocorre um evento, a probabilidade de sobrevivência será estimada pelo número dos que sobreviveram até aquele tempo ($R(t_j) - \Delta N(t_j)$) sobre os que estavam em risco naquele tempo ($R(t_j)$).
- Como os eventos são independentes, $S(t)$ é o produto das probabilidades de sobrevivência a cada tempo $t_j \leq t$.

Estimação não-paramétrica

Estimador de Kaplan-Meier

Dessa forma, temos a seguinte expressão:

$$\hat{S}_{KM}(t) = \frac{R(t_1) - \Delta N(t_1)}{R(t_1)} \times \frac{R(t_2) - \Delta N(t_2)}{R(t_2)} \times \dots \times \frac{R(t_m) - \Delta N(t_m)}{R(t_m)}$$


ou simplesmente

$$\hat{S}_{KM}(t) = \prod_{j:t_j \leq t} \frac{R(t_j) - \Delta N(t_j)}{R(t_j)}$$

Estimação não-paramétrica

Estimador de Kaplan-Meier

No R, o estimador de Kaplan-Meier está implementado na função `survfit`, que deve ser aplicada em um objeto `Surv`.



Estimação não-paramétrica

Estimador de Kaplan-Meier

Função de taxa de falha Acumulada

$$\hat{H}_{KM}(t) = \ln \hat{S}_{KM}(t)$$

Logo, pode-se estimar qualquer das funções.

No **R**, basta usar o argumento `cumhaz=TRUE` na função `plot`.

