

# Análise de sobrevivência e confiabilidade

Modelos paramétricos

---



Prof. Paulo Cerqueira Jr

Programa de Pós-Graduação em Matemática e Estatística - PPGME

Instituto de Ciências Exatas e Naturais - ICEN

<https://github.com/paulocerqueirajr> 

# Introdução

# Introdução

---

- O método de máxima verossimilhança somente deve ser aplicado após ter sido definido um modelo probabilístico adequado para os dados.
- Se um modelo for usado inadequadamente, toda a análise estatística fica comprometida e consequentemente as respostas às perguntas de interesse ficam distorcidas.
- A ideia empírica consiste em ajustar os modelos probabilísticos típicos para dados de tempos de vida e com base na comparação entre valores estimados e observados, decidir qual deles “melhor” se ajusta aos dados amostrais.
- A escolha da “melhor” distribuição pode ser feita por meio de técnicas gráficas ou testes de hipóteses com modelos encaixados.

# Introdução

---

- Método Gráfico.
  - Modelo candidato  $\times$  Kaplan-Meier.
  - Linearização do modelo.
- Teste de hipóteses: utilizar o TRV para comparar o modelo proposto com a gama generalizada.
- Critérios informação.
  - Critérios de informação de Akaike (AIC) e Bayesiano(BIC).

# Métodos gráficos

---

- Comparação direta da  $S(t)$  estimada do modelo proposto com o Kaplan-Meier (no mesmo gráfico) e **selecionar o modelo cuja curva melhor se aproximar da curva.**
- Duas formas:
  - $S_{KM}(t) \times S_{MP}(t)$ ;
  - $S_{KM}(t) \times \text{tempo}$  e  $S_{MP}(t) \times \text{tempo}$ , no mesmo gráfico.
- Linearização da  $S(t)$  para comparação com uma reta.

# Métodos gráficos

---

Exponencial:

$$S(t) = \exp\{-\alpha t\} \rightarrow -\log[S(t)] = \alpha t.$$

Weibull:

$$S(t) = \exp\{-(\alpha t)^\gamma\} \rightarrow -\log[S(t)] = (\alpha t)^\gamma \rightarrow \log[-\log[S(t)]] = \gamma \log(\alpha) + \gamma \log(t).$$

Lognormal:

$$S(t) = \Phi \{(-\log(t) + \mu)/\sigma\} \rightarrow \Phi^{-1} \{S(t)\} = (-\log(t) + \mu)/\sigma.$$

# Comparação para modelos encaixados

## Teste da razão de verossimilhanças

---

- Como foi dito anteriormente, as técnicas gráficas são extremamente úteis na seleção de modelos.
- Entretanto, as conclusões a partir delas podem diferir para diferentes analistas.
- Outra forma de discriminar modelos é através de testes de hipóteses e este caso, não envolve qualquer componente subjetivo na sua interpretação.
- As hipóteses:

$H_0$  : O modelo é adequado  $\times$   $H_1$  : O modelo não é adequado

# Comparação para modelos encaixados

## Teste da razão de verossimilhanças

---

- Neste teste, usa-se a razão de verossimilhanças em modelos encaixados (Cox e Hinkley, 1977).
- Ou seja, devemos usar um modelo generalizado tal que os de interesse sejam casos particulares.
- O teste:
  - Calcular  $\log L(\hat{\theta}_G)$ ;
  - Calcular  $\log L(\hat{\theta}_M)$ .



# Comparação para modelos encaixados

## Teste da razão de verossimilhanças

---

- A estatística da razão de verossimilhanças

$$TRV = -2 \log \left[ \frac{L(\hat{\theta}_M)}{L(\hat{\theta}_G)} \right] = 2 \log \left[ \log L(\hat{\theta}_G) - \log L(\hat{\theta}_M) \right],$$

sob  $H_0$ , tem aproximadamente uma distribuição qui-quadrado com graus de liberdade igual a diferença do número de parâmetros dos modelos sendo comparados.

# Critérios de informação

---

- Após encontrar as estimativas dos parâmetros de interesse, os critérios de informação são usados para selecionar o melhor modelo ajustado aos dados em questão.

Critério de informação de Akaike (AIC):

$$\text{AIC} = -2\ell(\theta \mid D) + 2k,$$

em que  $k$  é o número de parâmetros.

- Na presença de observações censuradas, o AIC pode não ser adequado. Dessa forma, Liang (2008), propôs uma versão modificada do AIC para dados censurados, e é expressa por

$$\text{AIC}_{\text{SUR}} = -2\ell(\theta \mid D) + 2k + \frac{2(k+2)(k+3)}{n-k-3},$$

em que  $k$  é o número de parâmetros,  $n$  é o tamanho amostral.

# Critérios de informação

---

Critério de informação Bayesiano(BIC):

- O critério de informação bayesiano é formalmente definido por

$$BIC = -2\ell(\theta \mid D) + k \log(n).$$

- Para cada critério definido, o menor valor indica a melhor qualidade de ajuste aos dados de interesse.

# Exemplo:

- Dados provenientes da UFPR.
- 20 pacientes com câncer de bexiga submetidos a um procedimento cirúrgico a laser.
- Resposta: tempo da cirurgia até a reincidência da doença (meses).
- Objetivo: mediano de vida destes pacientes.
- Dados (em meses): 17 falhas e 3 censuras.
- Modelos ajustados: Exponencial, Weibull e Lognormal e Gama generalizado.

```
1 require(survival)
2 require(flexsurv)
3
4 #require(survminer)
5
6 tempos<-c(3,5,6,7,8,9,10,10,12,15,15,18,
7           19,20,22,25,28,30,40,45)
8 cens<-c(1,1,1,1,1,1,1,0,1,1,0,1,1,1,1,1,
9          1,1,1,0)
10 dados <- data.frame(tempos, cens)
11 ekm <- survfit(Surv(tempos, cens)~1)
```

```
1 # Exponencial:
2 ajust1 <- survreg(Surv(tempos, cens)~1,
3                   dist='exponential')
4 alpha <- 1/exp(ajust1$coefficients[1])
5
6 # Weibull
7 ajust2 <- survreg(Surv(tempos, cens)~1,
8                   dist='weibull')
9 alpha.w <- exp(ajust2$coefficients[1])
10 gama <- 1/ajust2$scale
```

```
1 # lognormal:
2 ajust3 <- survreg(Surv(tempos, cens)~1,
3                   dist='lognormal')
4 mu <- ajust3$coefficients[1]
5 sigma <- ajust3$scale
6
7 # gamma:
8 ajust4 <- flexsurvreg(Surv(tempos, cens) ~
9                       dist = "gamma")
10 shape.g <- 1/ajust4$coefficients[1]
11 rate.g <- exp(ajust4$coefficients[2])
```

```
1 # gamma Gen:
2 ajust5 <- flexsurvreg(Surv(tempos, cens) ~
3                       dist = "gengamma.orig")
4 shape.gg <- exp(ajust5$coefficients[1])
5 scale.gg <- exp(ajust5$coefficients[2])
6 k.gg <- exp(ajust5$coefficients[3])
```

# Exemplo:

## Função de sobrevivência estimada

Exponencial:

$$S_E(t) = \exp\{-0.05t\}$$

Weibull:

$$S_W(t) = \exp\{-0.05t^{1.54}\}$$

Lognormal:

$$S_{LN}(t) = \Phi [-(\log(t) - 2.72)/0.76]$$

- Modelo Gama e Gama Generalizado obtidos numericamente.

# Exemplo - Método gráfico

```
1 #--- Função de sobrevivência:
2
3 tempo <- ekm$time
4 ste <- exp(-alpha*tempo)
5 stw <- pweibull(q = tempo, shape = gama, scale = alpha.w, lower.tail = FALSE)
6 stln <- pnorm( -(log(tempo)-mu)/sigma )
7 stgamma <- pgamma(q = tempo, shape = shape.g, rate=rate.g,
8                   lower.tail = FALSE)
9 stggamma <- pgengamma.orig(q = tempo, shape = shape.gg,
10                            scale =scale.gg, k = k.gg,
11                            lower.tail = FALSE)
12
13 cbind(tempo, ekm=ekm$surv, ste, stw, stln, stgamma, stggamma)
```


	tempo	ekm	ste	stw	stln	stgamma	stggamma
[1,]	3	0.95000000	0.8633164	0.95274148	0.98283934	0.83180159	0.97656309
[2,]	5	0.90000000	0.7827384	0.89897484	0.92624322	0.70824617	0.92159117
[3,]	6	0.85000000	0.7453152	0.86839357	0.88685752	0.65037389	0.88550195
[4,]	7	0.80000000	0.7096812	0.83609525	0.84337638	0.59583545	0.84591595
[5,]	8	0.75000000	0.6757509	0.80253272	0.79781416	0.54482327	0.80423301
[6,]	9	0.70000000	0.6434428	0.76809812	0.75169629	0.49737649	0.76158117
[7,]	10	0.65000000	0.6126794	0.73313414	0.70611769	0.45343783	0.71883800
[8,]	12	0.59583333	0.5554947	0.66278292	0.61931883	0.37557570	0.63555373
[9,]	15	0.54166667	0.4795676	0.55966698	0.50475984	0.28122913	0.52148679
[10,]	18	0.48148148	0.4140186	0.46346069	0.41042396	0.20931642	0.42390649
[11,]	19	0.42129630	0.3942241	0.43345774	0.38317692	0.18948996	0.39512627

# Exemplo - Método gráfico

Estimador de Kaplan-Meier × modelo ajustado.

```
1 tempo <- seq(0.0001, 50, length.out=1000)
2 ste <- exp(-alpha*tempo)
3 stw <- pweibull(q = tempo, shape = gama,
4               scale = alpha.w,
5               lower.tail = FALSE)
6 stln <- pnorm( -(log(tempo)-mu)/sigma )
7 stgamma <- pgamma(q = tempo, shape = shape.
8                 rate=rate.g, lower.tail =
9 stggamma <- pgengamma.orig(q=tempo, shape=s
10                          scale =scale.gg,
11                          lower.tail = FAI
```




```
1 plot(ekm, xlab="Tempo",
2       ylab="S(t)", mark.time=TRUE, conf.int=FAI
3 lines(tempo, ste, col=1)
4 lines(tempo, stw, col=2)
5 lines(tempo, stln, col=3)
6 lines(tempo, stgamma, col=4)
7 lines(tempo, stggamma, col=5)
8 legend("topright", c("Exp.", "W", "LN", "G",
```



# Exemplo - Método gráfico

## Linearização

```
1 par(mfrow=c(1,3))
2 st <- ekm$surv
3 invst <- qnorm(st)
4
5 plot(ekm$time, -log(st), pch=16, xlab="tempos", ylab="-log(S(t))", main="Exp.")
6 plot(log(ekm$time), log(-log(st)), pch=16, xlab="log(tempos)", ylab="log(-log(S(t)))", main="Weib.")
7 plot(log(ekm$time), invst, pch=16, xlab="log(tempos)", ylab=expression(Phi^-1 * (S(t))), main="LN.")
```





# Exemplo - TRV

- Comparação do modelo de interesse como o modelo Geral

```
1 trv_ge <- round(-2*( ajust1$loglik[1]-ajust5$loglik),2)
2 p_trv_ge <- pchisq(trv_ge, df = 2, lower.tail = FALSE)
3 trv_gw <- round(-2*( ajust2$loglik[1]-ajust5$loglik),2)
4 p_trv_gw <- pchisq(trv_gw, df = 1, lower.tail = FALSE)
5 trv_gln <- round(-2*( ajust3$loglik[1]-ajust5$loglik),2)
6 p_trv_gln <- pchisq(trv_gln, df = 1, lower.tail = FALSE)
7 trv_gg <- round(-2*( ajust4$loglik-ajust5$loglik),2)
8 p_trv_gg <- pchisq(trv_gg, df = 1, lower.tail = FALSE)
```

Modelo	$\log L(\theta)$	TRV	p-valor
Gama gen.	-65.69	-	-
Exponencial	-68.27	5.16	0.075774
Weibull	-66.13	0.88	0.3482017
Log Normal	-65.74	0.09	0.7641772
Gama	-65.85	0.31	0.5776802

# Critérios de informação


Menores valores de AIC,  $AIC_{Surv}$  e BIC indicam uma melhor qualidade de ajuste aos dados.

```
1 aic_e <- round(AIC(ajust1, k=1), 2)
2 aic_w <- round(AIC(ajust2), 2)
3 aic_ln <- round(AIC(ajust3), 2)
4 aic_g <- round(AIC(ajust4), 2)
5 aic_gg <- round(ajust5$AIC, 2)
6
7 aic_s_e <- round(AIC(ajust1, k=1) + ((2*(1+2)*(1+3)) / (dim(dados)[1]-1-3)), 2)
8 aic_s_w <- round(AIC(ajust2) + ((2*(2+2)*(2+3)) / (dim(dados)[1]-2-3)), 2)
9 aic_s_ln <- round(AIC(ajust3) + ((2*(2+2)*(2+3)) / (dim(dados)[1]-2-3)), 2)
10 aic_s_g <- round(AIC(ajust4) + ((2*(2+2)*(2+3)) / (dim(dados)[1]-2-3)), 2)
11 aic_s_gg <- round(ajust5$AIC + ((2*(2+2)*(2+3)) / (dim(dados)[1]-2-3)), 2)
12
13 bic_e <- round(BIC(ajust1), 2)
14 bic_w <- round(BIC(ajust2), 2)
15 bic_ln <- round(BIC(ajust3), 2)
```

Modelo	AIC	$AIC_{surv}$	BIC
Exponencial	137.55	134.75	139.54
Weibull	136.27	133.27	136.27
Log Normal	135.48	132.48	137.47
Gama	135.7	132.7	137.69
Gama Gen.	137.39	134.39	140.37

# Estimativas do modelo final

```
1 plot(ekm, xlab="Tempo",
2      ylab="S(t)", mark.time=TRUE, conf.int=TRUE,
3      lines(tempo, stln, col="red")
4      legend("topright", c("EKM", "LN"),
5            col=1:2, lty=1, bty="n")
```



Estimativas sobre o tempo:

Tempo mediano (EKM):

$$\hat{t}_{0,5;EKM} = 18 \text{ meses.}$$

Tempo mediano (Log-normal):

$$\hat{t}_{0,5} = 15.1375069 \text{ meses.}$$

Tempo medio (Log-normal):

$$\widehat{E(T)} = 20.2802566 \text{ meses.}$$